Análisis Comparativo del Desempeño de Proveedores Tecnológicos en el Servicio de Taxis de Nueva York

Alpizar Hernández Justin Alberto, Campos Aguilar Natalia, Chávez Pomajaca Joy Daniela, Gaitan Miranda Wishman

Facultad de Ingeniería, Universidad Fidélitas

San José, Costa Rica

jalpizar80778@ufide.ac.cr

ncampos10239@ufide.ac.cr

jchavez60736@ufide.ac.cr

wgaitan0904@ufide.ac.cr

Resumen – El presente proyecto tiene como objetivo desarrollar una solución de Inteligencia de Negocios mediante Microsoft Power BI para analizar y comparar el desempeño de los proveedores tecnológicos Creative Mobile Technologies (CMT) y VeriFone (VTS) en el servicio de taxis amarillos de Nueva York durante diciembre de 2019. Para ello, se utilizan registros históricos de viajes provenientes de la Taxi and Limousine Commission (TLC), disponibles en la plataforma Kaggle. Debido al volumen de información y a las inconsistencias identificadas, se aplica un proceso de extracción, transformación y limpieza (ETL), seguido de la construcción de un modelo dimensional. A partir de este modelo, se busca desarrollar un tablero interactivo con indicadores clave de rendimiento (KPIs) relacionados con la cantidad de viajes, pasajeros transportados, distancias, duración, tarifas, propinas e ingresos. Asimismo, se contempla el análisis de patrones temporales y de cobertura geográfica para identificar diferencias entre ambos proveedores. La solución permitirá transformar grandes volúmenes de datos en información útil para evaluar la eficiencia operativa, el desempeño económico y apoyar la toma de decisiones estratégicas basadas en datos.

Palabras Clave **–** Inteligencia de Negocios, Power BI, análisis de datos, indicadores clave de rendimiento (KPIs), transporte urbano, modelo dimensional, ETL, toma de decisiones.

Abstract – This project aims to develop a Business Intelligence solution using Microsoft Power BI to analyze and compare the performance of the technology providers Creative Mobile Technologies (CMT) and VeriFone (VTS) in New York City's yellow taxi service during December 2019. Historical trip records from the Taxi and Limousine Commission (TLC), available on the Kaggle platform, are used for this purpose. Due to the large volume of information and identified inconsistencies, an Extract, Transform, and Load (ETL) process is applied, followed by the development of a dimensional data model. Based on this model, the project seeks to develop an interactive dashboard featuring key performance indicators (KPIs) related to trip volume, passengers transported, distances traveled, trip duration, fares, tips, and revenue. Additionally, the analysis considers temporal patterns and geographic coverage to identify differences between the two providers. The proposed solution will transform large volumes of data into valuable information to evaluate operational efficiency, economic performance, and support data-driven strategic decision-making.

Keywords **–** Business Intelligence, Power BI, Data Analysis, Key Performance Indicators (KPIs), Urban Transportation, Dimensional Modeling, ETL, Decision-Making.

I. Introducción

El transporte público individual en la ciudad de Nueva York opera bajo la regulación de la Taxi and Limousine Commission (TLC), entidad que supervisa la operación, las tarifas y el registro de los viajes. Mediante el programa TPEP (Taxicab Passenger Enhancements Program), los taxis cuentan con sistemas tecnológicos de despacho, cobro electrónico y registro de viajes a bordo, suministrados por dos proveedores autorizados: Creative Mobile Technologies, LLC (CMT, VendorID 1) y VeriFone Inc. (VTS, VendorID 2). [1]

Cada viaje registrado por estos sistemas genera datos como la fecha y hora, la distancia, la tarifa, los recargos, la propina, el método de pago y las zonas de recogida y destino. La TLC publica estos registros como datos abiertos en archivos mensuales de gran volumen. En este contexto, la Inteligencia de Negocios (BI) ofrece un conjunto de técnicas para extraer, depurar, modelar y visualizar grandes cantidades de datos, con el fin de apoyar decisiones oportunas y basadas en evidencia.

Este proyecto utiliza los registros de taxis amarillos de diciembre de 2019, un mes de alta demanda por las festividades, el turismo invernal y las compras de fin de año, y previo a las disrupciones globales de movilidad. A partir de ellos se construye un modelo dimensional y un tablero interactivo en Microsoft Power BI, con métricas calculadas mediante DAX, para comparar el desempeño de los dos proveedores tecnológicos. [2],[3]

II. Objetivos

A. *Objetivo General*

Desarrollar un tablero de Inteligencia de Negocios en Microsoft Power BI que permita comparar la eficiencia operativa, la cobertura del servicio y la rentabilidad de los proveedores tecnológicos Creative Mobile Technologies (VendorID 1) y VeriFone (VendorID 2), a partir de los registros de viajes de taxis amarillos de Nueva York de diciembre de 2019.

B. *Objetivos Específicos*

- Caracterizar el contexto del programa TPEP y el rol de cada proveedor tecnológico en el registro de los viajes.
- Aplicar un proceso ETL que extraiga, depure y transforme los registros de diciembre de 2019 y los organice en un modelo dimensional con tabla de hechos y dimensiones relacionadas.
- Definir y calcular con DAX los indicadores clave (KPIs): viajes, pasajeros, distancia, duración, tarifa, recargos, propinas e ingresos totales.

- Analizar la distribución de las recogidas y destinos de cada proveedor para identificar diferencias de cobertura en zonas de alta congestión y zonas periféricas.
- Segmentar los resultados por proveedor, días festivos críticos y franjas horarias mediante visualizaciones interactivas.
- Formular conclusiones y recomendaciones basadas en la evidencia para la toma de decisiones.

III. Definición del Problema

A. *Contexto y Antecedentes*

Los informes consolidados son la base para tomar decisiones acerca de la implementación de plataformas tecnológicas en el transporte individual y la distribución de flotas, que no comparan el rendimiento de cada proveedor tecnológico bajo condiciones de alta exigencia. Diciembre es un escenario especialmente exigente por la combinación de festividades, turismo y compras de fin de año. Aun así, los datos que podrían sustentar una comparación rigurosa entre CMT y VeriFone se publican en archivos crudos y no integrados, que requieren un trabajo previo de preparación antes de poder usarse en la toma de decisiones.

B. *Volumen de los Datos*

En diciembre de 2019, el archivo de taxis amarillos suma 6,895,933 registros, de los cuales 2,283,202 (33.11 %) fueron procesados por CMT y 4,561,713 (66.15 %) por VeriFone. El 0.74 % restante (51,018 registros) no tiene proveedor identificado. Esta cantidad supera en más de seis veces el límite de 1,048,576 filas que admite una hoja de cálculo como Excel, por lo que no es posible analizarla con las herramientas tradicionales y se requiere una solución de Inteligencia de Negocios. [2]

C. *Calidad de los Datos*

Los registros presentan inconsistencias que distorsionan cualquier indicador si no se corrigen. En el archivo se identificaron 72,759 viajes con distancia igual a cero (1.06 %), 20,833 con tarifa negativa, 4,778 con duración menor o igual a cero y 125,331 con cero pasajeros (1.82 %). Además, 51,018 registros tienen valores nulos en las columnas de proveedor, pasajeros, código de tarifa, método de pago e indicador de almacenamiento del viaje. Esto demuestra que los datos no pueden usarse directamente para comparar proveedores y que necesitan un proceso de extracción, depuración y transformación.

D. *Diferencias entre Proveedores que los Reportes Agregados no Muestran*

Al separar los datos por proveedor aparecen diferencias que un reporte agregado oculta. VeriFone procesó aproximadamente el doble de viajes que CMT. La tarifa promedio fue de USD 13.34 con CMT y USD 13.50 con VeriFone, la distancia promedio de 2.81 y 3.02 millas, y la duración promedio de 14.98 y 20.21 minutos, respectivamente. La propina promedio fue de USD 2.17 con CMT y USD 2.31 con VeriFone (16.29 % y 17.07 % de la tarifa), y el ingreso por viaje fue de USD 19.29 y USD 19.61, con un recaudo total de USD 44,042,219.21 y USD 89,460,986.90. Estas cifras corresponden al archivo original, antes de la depuración.

También se observan diferencias en el recargo extra promedio (USD 2.63 con CMT y USD 0.33 con VeriFone) y en el registro de pasajeros: el 99.54 % de los viajes con cero pasajeros corresponde a CMT (124,759 viajes, el 5.46 % de sus registros), frente a 572 en VeriFone. Estas diferencias podrían estar relacionadas con la forma en que cada sistema registra los datos y no necesariamente con diferencias reales en el servicio, lo que refuerza la necesidad de analizarlas con un modelo estructurado.

E. *Variación en el Tiempo y en el Espacio*

La demanda cambia de forma importante durante el mes y el día. Se mantiene alta entre las 12:00 y las 21:59, con un pico entre las 18:00 y las 18:59 en ambos proveedores y un mínimo a las 4:00. Entre los días festivos, el 25 de diciembre fue el de menor actividad (100,857 viajes entre ambos proveedores, menos de la mitad del promedio diario), mientras que el 24 y el 31 registraron 162,856 y 167,609 viajes. El día de mayor actividad fue el 19 de diciembre, con 284,979 viajes.

En cuanto a cobertura, cerca del 20 % de los viajes de cada proveedor (20.36 % en CMT y 19.95 % en VeriFone) se concentra en cinco zonas de recogida de Manhattan: Upper East Side South, Upper East Side North, Midtown Center, Midtown East y Penn Station/Madison Sq West. Ambos comparten las mismas cinco zonas, con una diferencia en el orden: en CMT, Penn Station/Madison Sq West ocupa el tercer lugar, y en VeriFone, el quinto.

F. *Consecuencias y Planteamiento del Problema*

En consecuencia, administradores de flotas, inversionistas y tomadores de decisiones carecen de una herramienta que integre, depure y compare el desempeño de ambos proveedores en términos de eficiencia operativa, cobertura geográfica y rentabilidad. Esto limita las decisiones sobre alianzas comerciales, negociación de comisiones por cobro electrónico y despliegue de unidades en temporada alta. El problema central consiste en la ausencia de un modelo analítico y un tablero interactivo que, a partir de datos de calidad, permitan un benchmarking confiable entre los dos proveedores tecnológicos.

TABLA I
VOLUMEN Y CALIDAD DE LOS DATOS

Se menciona en c.2 y c.3: El archivo de diciembre de 2019 presenta el volumen y los problemas de calidad que resume la Tabla I.

Indicador	Registros	% del Total
Registros totales	6.895.933	100.00
Procesados por CMT (VendorID 1)	2.283.202	33.11
Procesados por VeriFone (VendorID 2)	4.561.713	66.15
Sin proveedor identificado	51.018	0.74
Distancia igual o menor a cero	72.759	1.06
Tarifa negativa	20.833	0.30
Duración igual o menor a cero	4.778	0.07
Cero pasajeros	125.331	1.82
Valores nulos en proveedor, pasajeros, tipo de tarifa, pago e indicador de almacenamiento	51.018	0.74

TABLA II
COMPARACIÓN ENTRE PROVEEDORES

Se menciona en c.4: La Tabla II compara los indicadores principales de ambos proveedores.

Indicador	CMT	VeriFone
Viajes	2,283,202	4,564,713
Pasajeros transportados	2,913,727	7,701,843
Distancia promedio (millas)	2,81	3,02
Duración promedio (min)	14,98	20,21
Tarifa promedio (USD)	13,34	13,50
Recargo extra promedio (USD)	2,63	0,33
Recargo por congestión promedio (USD)	2,30	2,29
Propina promedio (USD)	2,17	2,31
Propina sobre la tarifa (%)	16,29	17,07
Ingreso total (USD)	44,042,219.21	89,460,986.90
Ingreso por viaje (USD)	19,29	19,61
Viajes con cero pasajeros	124,759	572
Cero pasajeros sobre sus viajes (%)	5,46	0,01

Nota: Cifras del archivo original, antes de depurarlo.

TABLA III
DÍAS FESTIVOS CRÍTICOS

Se menciona en c.5: La Tabla III muestra la caída de actividad el 25 de diciembre frente a otros días del mes.

Día	CMT	VeriFone	Total
24 de diciembre	52,273	110,583	162,856
25 de diciembre	28,481	72,376	100,857
31 de diciembre	54,258	113,351	167,609
19 de diciembre (día de mayor actividad)	96,971	188,008	284,979

TABLA IV
ZONAS DE RECOGIDA CON MÁS VIAJES

Se menciona en c.5: La Tabla IV presenta las cinco zonas de recogida con mayor número de viajes por proveedor.

Posición	CMT	VeriFone
1	Upper East Side South (110,370)	Upper East Side South (213,143)
2	Upper East Side North (100,725)	Upper East Side North (186,731)
3	Penn Station/Madison Sq West (87,823)	Midtown Center (178,845)
4	Midtown Center (86,057)	Midtown East (166,155)
5	Midtown East (79,811)	Penn Station/Madison Sq West (165,349)

Como parte del proceso ETL se partió de un archivo de 6,896,317 registros. Se eliminaron 384 registros con fecha fuera de diciembre de 2019, 72,759 con distancia menor o igual a cero, 20,038 con tarifa menor o igual a cero y 306 con duración menor o igual a cero o superior a 24 horas, para un total de 93,487 registros eliminados (1.36 %). El conjunto depurado quedó en 6,802,830 registros (98.64 %). Las reglas se aplicaron de forma secuencial, por lo que cada viaje se contabiliza una sola vez, en la primera regla que incumple. Los 51,018 registros sin proveedor no se eliminaron, sino que se marcaron como "No identificado", pues conservan información válida de tarifas, distancias y zonas; en las comparaciones entre proveedores se excluyen mediante un filtro. Los viajes con cero pasajeros tampoco se eliminaron y solo se excluyen de las medidas de pasajeros. [4]

TABLA V
DEPURACIÓN DE LOS REGISTROS (ETL)

Regla de depuración (en orden)	Registros eliminados	% del archivo inicial
Fecha fuera de diciembre de 2019	384	0,01
Distancia igual o menor a cero	72,759	1,06
Tarifa igual o menor a cero	20,038	0,29
Duración igual o menor a cero, o mayor a 24 horas	306	menos de 0,01
Total eliminado	**93,487**	**1,36**
Registros iniciales	6,896,317	100,00
Registros finales	**6,802,830**	**98,64**

Nota: las reglas se aplican de forma secuencial. Cada registro se cuenta una sola vez, en la primera regla que incumple, por lo que los conteos pueden diferir de los totales por problema del archivo original.

```
[Running] py -3.12 "c:\Proyecto_InteligenciaDeDatos\etl_taxis_diciembre_2019.
py"
Registros iniciales del archivo: 6896317
Fecha fuera de diciembre 2019: 384 registros eliminados
Distancia igual o menor a 0: 72759 registros eliminados
Tarifa igual o menor a 0: 20038 registros eliminados
Duraci?n menor o igual a 0 o mayor a 24 horas: 306 registros eliminados
Registros finales: 6802830
Listo, archivos generados
```

Fig. 1 Elaboración propia a partir de los datos de la TLC.

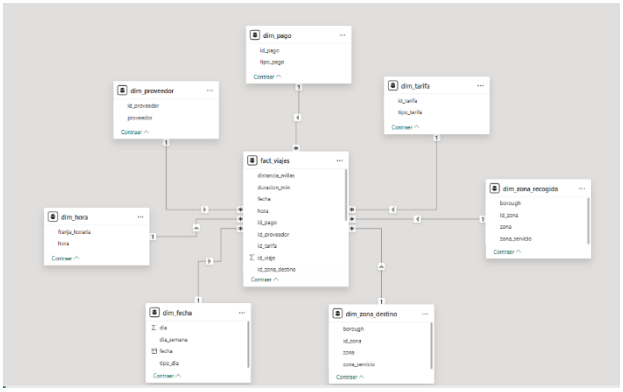


Fig- 2 Elaboración propia a partir de los datos, el modelo estrella.



Fig. 3 Barra de referencia del total de los viajes a partir de los datos.

IV. JUSTIFICACION

El sector de transporte público individual en la ciudad de Nueva York opera bajo un esquema altamente competitivo regulado por la Taxi and Limousine Commission (TLC), donde la tecnología de gestión, despacho y cobro a bordo está dividida principalmente entre dos grandes proveedores tecnológicos autorizados por el programa TPEP (Taxicab Passenger Enhancements Program): Creative Mobile Technologies, LLC (CMT / VendorID: 1) y VeriFone Inc. (VTS / VendorID: 2) [1].

La ejecución de este proyecto es necesaria debido a que, tradicionalmente, las decisiones operativas, la asignación de flotas y la adopción de plataformas tecnológicas se sustentan en reportes agregados que no evalúan el rendimiento comparativo de cada proveedor bajo condiciones de máxima exigencia operativa [5]. El mes de diciembre de 2019 representa el período de mayor demanda y estrés logístico del año —impulsado por festividades, turismo invernal y compras de fin de año en la etapa previa a las disrupciones globales de movilidad—, lo que lo convierte en el escenario de referencia idóneo para contrastar de manera rigurosa la eficiencia operativa, cobertura de servicio y rentabilidad entre ambos operadores tecnológicos a partir de registros masivos de viajes [1].

Impacto del proyecto

- Impacto Operativo y Logístico: Proporciona un marco cuantitativo para comparar indicadores clave de rendimiento (KPIs), tales como tiempos promedio de viaje, volumen de pasajeros movilizados, distancias recorridas y distribución geoespacial de recogidas y llegadas. Esto permite identificar cuál proveedor ofrece una mejor cobertura en zonas de alta congestión o áreas periféricas durante horas pico decembrinas [1], [5].
- Impacto Económico y Financiero: Facilita a administradores de flotas, inversionistas y tomadores de decisiones la evaluación de la rentabilidad por viaje, el comportamiento de tarifas base, recargos y tasas de propina generadas por cada plataforma, permitiendo determinar con métricas concluyentes qué ecosistema maximiza el retorno de inversión y minimiza tiempos muertos [6].
- Impacto Estratégico en la Toma de Decisiones: Transforma millones de registros transaccionales en un activo analítico de alto nivel, permitiendo fundamentar alianzas comerciales, negociaciones de comisiones por procesamiento de cobros electrónicos y el despliegue eficiente de unidades basadas en evidencia [6].

Innovación del proyecto: La innovación del estudio radica en la transición de un tratamiento de datos plano y reactivo hacia una arquitectura moderna de Inteligencia de Negocios estructurada en Microsoft Power BI [6]. A diferencia de los análisis descriptivos tradicionales en hojas de cálculo estáticas:

- Se implementa un modelo de datos analítico multidimensional optimizado para la gestión masiva de transacciones del sector transporte [5], [6].
- Se incorporan métricas dinámicas calculadas mediante DAX (Data Analysis Expressions), facilitando la segmentación instantánea por proveedor (VendorID), días festivos críticos y franjas horarias específicas [6].
- Se habilita un entorno de visualización interactivo y geoespacial que correlaciona de forma directa las variables financieras (facturación, propinas) con las variables logísticas (zonas de recogida y destino), ofreciendo un cuadro de mando ejecutivo intuitivo para el benchmarking continuo entre ambos proveedores tecnológicos [5], [6].

V. Requerimientos

TABLA VI
REQUERIMINTOS DEL PROYECTO

La tabla VI indica lo que necesita el dashboard para responder a los objetivos específicos planteados.

Código	Descripción	Prioridad
COD-001	Mostrar los indicadores principales: viajes, pasajeros, distancia promedio, duración promedio, tarifa promedio, propina promedio, ingreso total e ingreso por viaje para cada uno de los proveedores.	Alta
COD-002	Mostrar la distribución de viajes según la franja horaria y día de la semana para identificar las horas con mayor y menor demanda de cada proveedor.	Alta
COD-003	Mostrar las zonas y boroughs de recogida y destino con más viajes por proveedor.	Alta
COD-004	Comparar la distribución entre los métodos de pago y los tipos de tarifa según el proveedor.	Baja
COD-005	Comparar la evolución diaria de viajes e ingresos durante diciembre de 2019 para cada proveedor	Alta
COD-006	Comparar la actividad de los días festivos con el promedio diario del mes por proveedor	Alta
COD-007	Calcular el porcentaje de propina usando solo los pagos con tarjeta para cada proveedor.	Media
COD-008	Permitir segmentar la información por proveedor, fecha, franja horaria, borough, método de pago y tipo de tarifa	Alta

VI. Descripción de las Fuentes

La principal fuente de información del proyecto corresponde al dataset New York City Yellow Taxi Trip Data 2019–2020. Este conjunto recopila registros históricos de viajes de taxis amarillos de Nueva York, provenientes de la Taxi and Limousine Commission (TLC), entidad encargada de regular este servicio de transporte [1], [2].

Para el desarrollo del análisis se utiliza el archivo correspondiente a diciembre de 2019, que contiene información sobre fechas y horas de recogida y destino, cantidad de pasajeros, distancias recorridas, tarifas, recargos, propinas, métodos de pago, ubicaciones y proveedores tecnológicos identificados mediante el campo VendorID.

Esta fuente constituye la base del proyecto, ya que permite comparar el comportamiento operativo y económico de Creative Mobile Technologies (CMT) y VeriFone (VTS). A partir de sus registros se calcularán indicadores clave de rendimiento relacionados con el volumen de viajes, duración, distancias, ingresos y distribución geográfica y temporal de la demanda.

Debido al volumen de información y a las inconsistencias identificadas, los datos serán sometidos a un proceso de extracción, transformación y limpieza (ETL), para posteriormente integrarse en un modelo dimensional en Microsoft Power BI. Esto permitirá desarrollar visualizaciones interactivas que faciliten la identificación de patrones y respalden la toma de decisiones.

Referencias

[1] New York City Taxi and Limousine Commission (TLC), "2019 Yellow Taxi Trip Data," recopilado por Microize en Kaggle, 2021. [En línea]. Disponible en: https://www.kaggle.com/datasets/microize/newyork-yellow-taxi-trip-data-2020-2019

[2] Kaggle. (2020). New York City yellow taxi trip data (2019–2020) [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/microize/newyork-yellow-taxi-trip-data-2020-2019/data

[3] Microsoft. (2024). Power BI Desktop (versión 2.126) [Software]. Microsoft Corporation. https://powerbi.microsoft.com/

[4] The pandas development team. (2024). Pandas (versión 2.2.3) [Software]. Zenodo. https://doi.org/10.5281/zenodo.13819579

[5] R. Sharda, D. Delen y E. Turban, Business Intelligence, Analytics, and Data Science: A Managerial Perspective, 4.ª ed. Boston, MA, EE. UU.: Pearson, 2018.

[6] Microsoft Corporation, "Documentación sobre Power BI: Información general sobre el modelado de datos y DAX," Microsoft Learn, 2023. [En línea]. Disponible en: https://learn.microsoft.com/es-es/power-bi/